

BankOCR

银行流水识别助手 V1

Design Specification

本地离线 • CPU-first • 可追溯 • 可复核

文档版本	1.1
日期	2026-08-09
设计状态	开发基线（已完成设计评审）
目标环境	Windows x64；16GB 内存；CPU-first；独显非必需

V1 主路线：RapidOCR + PP-OCRv6-small + ONNX Runtime CPU + OpenCV + 模板优先 / 通用兜底
+ 确定性财务校验

核心原则：机器负责批量识别，人只处理真正的不确定性；所有关键结果均可回到原 PDF 复核。

阅读导航

A. 产品与边界	第 1-5 节：目标、范围、硬件、隐私与非功能要求
B. OCR 与表格解析	第 6-18 节：架构、预检、坐标、模板、Parser、校验与风险
C. 用户产品与部署	第 19-30 节：复核、输出、任务队列、GUI、安全、打包、升级
D. PoC 与发布验收	第 31-37 节：Golden Set、Benchmark、测试、目录、风险
E. 设计审查与路线图	第 38-40 节：本次修改、后续版本、V1 锁定结论

v1.1 设计复审在原有页级 PDF 分类、CoordinateTransform、Generic fail-closed、Silent Critical Error、流式处理、Run pinning 与离线升级基础上，进一步纳入 Native Text Quality Gate、字段级多来源追溯、交易结构人工修正、Generic 首屏列映射确认、验证四态语义、anchor-normalized 模板坐标，以及 Calibration / Regression / Locked Holdout 三层 Benchmark。

1. 文档目的

本规格说明书定义 BankOCR V1 的产品边界、用户流程、技术架构、数据结构、OCR 与表格解析策略、财务校验、人工复核、输出文件、离线部署、安全与可追溯要求、PoC/Benchmark 验收标准以及未来模型和方案升级机制。

V1 的核心目标不是“做一个通用 OCR 软件”，而是把法院或银行提供的纸质扫描银行流水，在普通律所 Windows 办公电脑上离线转换为可检索、可筛选、可人工复核、可追溯的结构化数据。

2. 设计依据与样本类型

首批 PoC 以两类真实扫描银行流水为基准：

- **样本 A：有线/断续线表格。** 横竖表格线存在但不连续，单元格内容可能换行，传统 OCR 容易把线条识别成字符并破坏阅读顺序。
 - **样本 B：无线/位置型表格。** 缺少完整竖线，主要依靠固定列位置排版，并存在印章覆盖正文或表头的情况。
- 两类样本均属于扫描 PDF 场景，V1 同时支持 born-digital PDF、纯扫描 PDF 和页级混合 PDF。

3. 产品目标

3.1 核心用户

主要用户为律师、律师助理、执行/调查团队成员，以及负责模板维护和软件部署的内部管理员。

3.2 核心任务

用户将 100-200 页甚至更大的银行流水 PDF 拖入软件，软件完成页级预检、OCR、版面解析、交易重建、财务校验和异常检测，并生成：

1. 结构化 Excel;
2. 可搜索 PDF;
3. 异常复核 Excel;
4. 本地项目数据库和处理清单，用于断点恢复、复核和追溯。

3.3 用户体验目标

正常用户不需要安装 Python、输入命令、选择 OCR 参数、判断 DPI 或手工选择模板。主流程控制在：

拖入 PDF → 文件体检 → 开始识别 → 查看异常 → 确认/修正 → 导出结果

4. V1 范围

4.1 V1 必须包含

- Windows 桌面 GUI;
- 单个或多个 PDF 拖拽导入;
- 页级 PDF 类型判定：原生文本、扫描图像、混合页面;
- 原生 PDF 文字层质量门禁（Native Text Quality Gate），异常文字层自动回退页面/区域 OCR;
- RapidOCR + PP-OCrv6-small OCR 基线;
- ONNX Runtime CPU 基线;
- OpenCV 图像预处理与有线表格结构恢复;
- Known Template、Generic Parser 两级处理;
- Generic 模式首屏列映射确认，并生成当前项目/Run 作用域的 Temporary Template;
- Wired / Semi-Wired / Positional 三类解析器;
- 交易行重建、多行单元格合并、跨页连续性检测;
- 确定性金额/余额/日期/账号校验;
- 可疑单元格二次 OCR;
- 风险分级与异常复核界面;
- 复核界面支持字段修正以及合并/拆分/移动/新增交易行等结构修正;
- Excel、可搜索 PDF、异常清单输出;
- 多任务排队、暂停/取消、断点恢复;
- 原始 PDF 不改写、SHA-256 记录;
- 字段级 provenance 支持一个最终值追溯到一个或多个原始 TextBlock/source span;
- 完全离线运行，无登录、无 API Key、无 telemetry、无自动上传;
- 版本化 Run Manifest、模板、模型、解析器和校验规则;
- 回归 benchmark 与升级回滚机制。

4.2 V1 明确不包含

- 云端 OCR 或云端大模型;
- 本地 VLM/LLM 作为主 OCR 或最终数值判断器;
- 自动资金路径分析、关系图谱、案件智能研判;
- 通用合同/票据/身份证 OCR 产品化;

- 在线自动更新；
- 自动训练或基于用户数据的自学习；
- 复杂多人协作、账号体系和服务器端权限系统；
- 对任何陌生银行版式承诺与 Known Template 相同的准确率。

5. 非功能要求

5.1 硬件与资源

基线设备为 16GB 内存、SSD、Intel/AMD 主流办公 CPU。程序必须在无 NVIDIA 独显时完整工作。GPU/NPU 加速只作为未来可插拔能力，不作为 V1 依赖。

处理采用有界队列和流式页面处理，默认不长期保存全部 300 DPI 中间 PNG。页面处理完成后立即释放大图，只保留必要数据库记录、异常裁剪图（若启用）和可重建信息。

5.2 性能目标

V1 不在设计阶段承诺固定“200 页几分钟”，以 benchmark 实测为准。目标是在基线 16GB 办公机上保持 GUI 可响应、内存可控，并让用户在 OCR 后台运行时仍可使用常规办公软件。


初始工程目标：峰值内存尽量控制在 6GB 以内；若 benchmark 超出，通过限制 worker 数、页面分辨率和缓存策略降低资源占用。

5.3 隐私与网络

运行期不需要互联网。模型、模板和运行时依赖随安装包或离线模型包提供。默认技术日志不记录银行账号、姓名、金额、OCR 全文等业务内容。

V1 的应用层安全目标主要是阻止不必要的网络外发、减少临时数据和保证可追溯，不自行实现一套文件加密系统。生产部署应使用律所受管设备和操作系统级磁盘加密/访问控制；若未来需要案件级加密容器，应作为单独安全需求设计和审计。

6. 总体架构





7. 页级预检与路由

PDF 类型判定必须按“页”而不是按“整份文件”完成，以支持同一 PDF 中原生页和扫描页混合的情况。

每页至少产生以下状态之一：

- NATIVE_TEXT：检测到文字层后先进入 Native Text Quality Gate；只有通过质量门禁才优先直接抽取文字及坐标，否则将页面或可疑区域栅格化后进入 OCR；
- SCAN_IMAGE：无可靠文字层，进入渲染与 OCR；
- HYBRID：同时包含文字和扫描内容。原生文字先经过 Native Text Quality Gate；通过的区域保留原生 TextBlock，对缺失或质量异常区域做 OCR，并按坐标重叠去重，避免同一文字被 native text 与 OCR 重复计入；
- PAGE_ERROR：页损坏、无法渲染或读取失败。单页失败默认不终止整份任务，记录原因后继续处理后续页，并把该页列入整页复核。

预检同时检查：

- PDF 是否损坏；
- 是否密码保护；
- 输出目录是否可写；
- 磁盘空间是否足够；
- 页面旋转、明显倾斜；
- 空白页；
- 疑似重复页；
- 页面尺寸/方向突变；
- 已处理过的相同源文件 SHA-256。

对于密码保护 PDF，密码只在当前会话内使用，默认不写入项目数据库或日志。

Native Text Quality Gate 至少检查：文本是否出现异常乱码/不可打印字符、文字框坐标是否越界或高度异常、文本覆盖密度与页面视觉内容是否明显不匹配、关键日期/金额区域是否存在严重抽取缺口。门禁失败不等同于文件失败，而是触发该页或可疑区域的 Rasterize + OCR fallback；后续财务/结构校验若发现原生文字与视觉版面明显矛盾，也允许升级到 OCR 复核。

8. 统一中间数据模型

8.1 TextBlock

无论文字来自 PyMuPDF 原生文本层还是 RapidOCR，都转换为统一 TextBlock：

```
text
polygon / bbox
confidence          # OCR model confidence; native_pdf 可为 None
source_type         # native_pdf / ocr
page_index
engine_id
raw_text
text_block_id
```

原生 PDF 文字不伪装成 OCR confidence=1.0。OCR confidence 只表示 OCR 模型自身置信度；native_pdf TextBlock 的 confidence 可为 None，其可靠性由独立的 Native Text Quality Gate / page quality 结果表达。无论来源如何，文本仍须经过结构与财务校验。

8.2 CoordinateTransform

图像可能经历缩放、旋转、deskew、裁剪和去线。每页必须保存从处理图坐标回到原 PDF 页坐标的可逆变换信息。

这是复核界面准确框选原件、构建 searchable PDF 隐藏文字层以及审计追溯的基础。任何 parser 不得直接假设 OCR bbox 等于原 PDF 坐标。

8.3 TransactionRecord

统一交易记录至少包含：

```
transaction_id
statement_stream_id
page_index
row_index
transaction_date
transaction_time
currency
income
expense
signed_amount
debit_credit_direction
balance
summary
counterparty_account
counterparty_name
counterparty_bank
own_account
own_account_name
source_bbox
parser_id
template_id
status
risk_score
```

所有金额使用 Decimal，不使用二进制 float。

8.4 ProvenanceValue

金额、余额、日期、账号等关键字段采用带来源链的数据对象：

```
raw_blocks[]          # 原始 TextBlock / OCR block 文本
source_spans[]         # (page_index, bbox/polygon, text_block_id)
normalized_value
suggested_value
```

```
final_value
ocr_confidence
secondary_ocr_value
correction_source
review_status
```

source_spans[] 是字段级追溯的强制能力：一个最终字段可以对应一个或多个原始文字块。例如三行公司名称合并为一个 counterparty_name 时，三个原始 bbox 均须保留；交易拆分、合并或人工移动字段时也不得丢弃原始 source span。TransactionRecord.source_bbox 可继续作为整笔交易的聚合区域，但不能替代字段级 provenance。

9. 图像处理

9.1 双通道预处理

同一页面使用不同处理目标：

- OCR 通道：纠偏、去噪、对比度增强、必要时轻微锐化；
- Structure 通道：二值化、水平/垂直结构提取、形态学 closing、断线修补。

不得为了去表格线而覆盖原始扫描图。

9.2 页面方向

支持 90/180/270 度方向检测和小角度 deskew。所有变换必须进入 CoordinateTransform。

9.3 印章干扰

V1 不“删除”印章，也不修改原始证据图。对于彩色印章覆盖黑色文本的情况，可在二次 OCR 中实验不同颜色通道/灰度策略，并把结果作为候选而非静默修正。

10. OCR Engine 层

10.1 V1 基线

V1 首选：

- RapidOCR；
- PP-OCRv6-small detection + recognition；
- ONNX Runtime CPU；
- 中文/中英文混排；
- Python 3.12 候选运行时。

PoC 必须把实际使用的 wheel、模型文件和 SHA-256 固定进 lock/manifest，不能依赖运行时自动下载模型。

10.2 OCR Engine Interface

OCR 引擎只负责返回 TextBlock 集合，不了解银行、余额或交易语义。

```
OCRBackend.recognize(page_image, options) -> OCRPageResult
```

后续可添加 OpenVINO、新版 PP-OCR、其他 ONNX 模型或 VLM 辅助引擎，而不改变 parser / validator / exporter 接口。

10.3 V1 加速策略

V1 以 ONNX Runtime CPU 为强制基线。Intel 设备可将 OpenVINO 作为 PoC benchmark 的可选执行后端；只有当同一 Golden Set 上准确性无回退且部署复杂度可控时才进入正式包。

V1 不承诺 DirectML/CUDA 自动加速；Windows GPU/NPU 加速留在后续版本的 Engine Provider 层实现。

11. 银行模板系统

模板是版本化配置，不把银行版式逻辑硬编码到 GUI 或 OCR 引擎。

每个模板包含：

- `template_id/version`;
- 银行与文档类型特征；
- 标题/表头锚点；
- 列顺序、表格区域（table box）以及 anchor/table-local 相对坐标；
- 表格类型：WIRED / SEMI_WIRED / POSITIONAL；
- 日期/金额/借贷方向规则；
- 页眉页脚排除区域；
- 余额链方向（正序/倒序）；
- 可选页面合计字段；
- 支持字段与已知限制。

模板坐标优先保存为相对于 table box / header anchors 的归一化坐标，而不是相对于整页的固定像素或单纯 page-relative X。运行时先定位表格区域和稳定表头锚点，再把表格局部坐标归一化到 0-1；page-relative 坐标只作为无法稳定定位 table box 时的 fallback。这样可降低页边距变化、扫描裁边、打印缩放和页面轻微偏移导致的模板漂移。

12. 模板匹配

模板指纹综合：银行名称、标题、表头字段、表头顺序、列数、anchor/table-local 相对坐标、线条密度等。

不在设计中硬编码“80%”等固定模板阈值。模板匹配阈值属于版本化配置，必须通过 Golden Set 对“错套模板”的代价进行校准。宁可进入 Generic/Review，也不强行套用低置信模板。

同一 PDF 每页持续进行轻量版式健康检查；发生表头漂移、列位移或版式突变时重新匹配模板，允许一份 PDF 中途换版式。

13. 三类 Parser

13.1 Wired Parser

OpenCV 恢复水平/垂直表格骨架，得到行列边界，再根据 OCR block 的中心点和重叠关系归入 cell。

13.2 Semi-Wired Parser

当横线或竖线不完整时，只采用可靠的线条信息，并结合表头/列坐标、日期锚点和 OCR block 聚类。

13.3 Positional Parser

对于无线表格，用表头和模板确定列带；交易行优先由日期 OCR block 作为 row anchor。多行对方名称/账号/摘要在同一交易 band 内合并。

13.4 Generic Parser

Unknown Template 首先识别表头别名，再推断列中心和边界，判断有线/无线版式并建立临时模板。

Generic 模式采取 **fail-closed** 原则：如果关键列无法可靠映射，不应猜测生成“看起来完整”的结构化流水，而应把页面或项目标为 PAGE_REVIEW，保留 OCR 文本和候选结构供人工确认。

13.5 Generic 首屏列映射确认

Generic fail-closed 之后必须存在用户可恢复路径。对陌生银行或低模板匹配度文档，系统在代表性首屏/首两页展示推断的列边界与标准字段映射（如日期、收入、支出、余额、摘要、对方账号、对方名称），让用户只确认或修改“列角色”，不暴露 OCR 深层参数。

用户确认后生成仅对当前项目/Run 生效的 Temporary Template；后续页面继续使用该模板，但仍保持较高的 Generic 风险权重和首批页抽检。Temporary Template 不自动写入全局模板库；如需升级为正式模板，必须通过开发/管理员模板工具、ground truth 对比和模板回归后再发布。

14. 交易行与跨页重建

交易行重建优先使用日期/交易时间/金额布局等锚点，而不是 OCR 返回顺序。

必须处理：

- 同一天多笔交易；
- 单元格多行；
- 页首/页尾重复表头；
- 正序/倒序流水；
- 多币种；
- 同一 PDF 多账号或多 statement section；
- 页间连续性；
- 疑似跨页截断记录。

余额校验链以 statement_stream_id 分组，至少由账户、币种、文档区段等信息构成，禁止在不同账户/币种/不连续区段之间盲目串联余额。

15. 数据标准化

允许自动执行“无语义变化”的安全标准化：

- 全角/半角符号统一；
- 日期分隔符统一；
- 数字千分位标准化；
- 前后空白与显然的 OCR 换行清理；
- 金额 Decimal 化。

金额、余额、日期、账号发生内容字符替换时只能生成 suggested_value，不得静默覆盖 raw_value。

负数、括号负数、CR/DR、借贷方向等必须由模板或明确规则解释，不得仅凭正负号主观推断。

16. 确定性财务校验

每条确定性校验规则必须返回四态结果，而不是简单二元“通过/失败”：

PASS / FAIL / INDETERMINATE / NOT_APPLICABLE

FAIL 仅用于证据充分且关系明确不成立的情况；INDETERMINATE 表示缺少前置余额、页面有缺口或上下文不足而无法判断；NOT_APPLICABLE 表示该银行/字段语义本身不适用该规则。风险评分不得把 INDETERMINATE 或 NOT_APPLICABLE 简单等同于 FAIL。

至少包含：

- 日期合法性与顺序；
- 金额格式；
- 余额连续性；
- 收入/支出与借贷方向一致性；
- 前后双向余额关系；
- 多币种独立余额链；
- 页间连续性；
- 页面/期间合计（若原表提供）；
- 账号字符/长度异常；
- 疑似重复交易解析；
- 疑似漏交易行；
- 整页交易数量/健康度异常。

余额关系示例：

```
current_balance = previous_balance + income - expense
```

或按模板使用 signed amount / debit-credit 规则。

17. 二次 OCR

第一次 OCR 或验证失败时，不重跑整个 PDF，而只对可疑区域裁剪并二次识别。

二次 OCR 可以尝试：

- 原 crop；
- 2x 放大；
- 对比度增强；
- 自适应二值化；
- 去表格线版本；
- 彩色扫描下的替代颜色通道。

多个候选结果结合字段类型、OCR 置信度和确定性财务关系生成建议。无法收敛时进入人工复核。

18. 风险与异常评分

风险评分必须可解释、规则化、版本化，不使用黑箱模型作为最终风险判断器。

评分输入包括：

- 字段级 OCR confidence；
- 二次 OCR 一致性；
- 余额校验；
- 确定性校验四态结果（PASS / FAIL / INDETERMINATE / NOT_APPLICABLE）；
- 列/行归属置信度；
- Known/Generic 模式；
- 页面健康度；
- 漏行/重复行检测；
- 核心字段类型。

金额、余额、日期、交易行存在性属于 Critical；账号/对方名称属于 High；摘要等通常属于 Medium/Low。

OCR confidence 阈值和 risk score 分值不固定写死。不同模型的 confidence 分布不可直接等同，初始阈值通过 Golden Set 按字段校准并作为 ValidationRulesVersion 发布。

风险引擎应区分“明确错误”和“无法判断”：FAIL 对 Critical 字段可显著提升风险；INDETERMINATE 通常触发 review 或上下文检查，但不应在统计中被报告为确定性校验失败；NOT_APPLICABLE 不产生异常分。

19. 人工复核

复核 UI 采用“原始 PDF/局部放大 + 上一笔/当前笔/下一笔交易上下文 + 结构化字段 + 异常原因”同屏方式。余额异常、串行和跨行问题默认显示前后交易，减少用户在 PDF 与 Excel 之间来回查找。

用户至少可以：

- 接受机器建议；
- 手工输入最终值；
- 把字段移动到上一笔/下一笔交易；
- 合并当前交易与上一笔/下一笔；
- 将一笔错误合并的交易拆分为两笔或多笔；
- 新增疑似漏识别的交易行，并要求选择原页/原始 source span；
- 标记疑似重复解析交易并保留原始候选；
- 标记原件不可辨认；
- 跳过并保持未解决；
- 按高/中/低风险过滤；
- 按金额、余额、账号、页面异常过滤；
- 使用快捷键快速上一条/下一条/确认。

人工修改必须保留：旧值、新值、修改时间、可选 reviewer 标识和异常原因。修改后可重新导出 Excel/PDF，无需重新 OCR。

结构修正与字段修正使用同一审计原则：必须保存 machine candidate、人工操作类型、涉及的 transaction_id / source_spans、修改前后结构、时间和 reviewer。不得通过覆盖/删除原始候选来“修好”结果。

如果仍有高风险未处理，允许导出，但必须在导出确认和处理报告中明确显示未解决数量，不能把其伪装成“全部通过”。数据库中的 final_value 对未人工确认的关键异常保持为空；主 Excel 如为工作便利展示机器候选值，该单元格必须明显高亮并配合 状态=待复核，来源索引同时保留 raw/suggested/final 三层值，避免把机器候选误当成人工确认事实。

20. 输出文件

20.1 结构化 Excel

建议至少包含三张 Sheet：

- 全部流水：日期、收入、支出、余额、摘要、对方账号、对方名称、页码、状态等；
- 处理报告：源文件 SHA-256、页数、引擎/模型/模板/规则版本、总交易数、自动通过数、人工确认数、未解决数、处理时间，以及本次导出各输出文件 SHA-256；
- 来源索引：transaction_id、field、source_spans[]、raw blocks、secondary OCR、confidence、parser/template、validation finding，以及人工结构修正审计信息。

日期和金额写成真正的 Excel 日期/数值，不输出为不可计算的字符串。

每次完成导出后，对结构化 Excel、可搜索 PDF 和异常复核文件计算 SHA-256。输出 hash 用于证明“程序当时生成的版本”是否后来被修改；它不是电子证据鉴定结论，但属于内部可追溯链。

20.2 异常复核 Excel

包含：页码、交易序号、风险等级、异常字段、raw value、建议值、最终值、原因、是否人工确认。

20.3 Searchable PDF

原始 PDF 永不覆盖。输出一个新的“可搜索副本”。

优先 PoC：复用统一 TextBlock 和原 PDF 坐标，用 PyMuPDF 写入 invisible text layer。隐藏文字层默认使用 OCR/原生识别文本，不做语义重写；人工结构化修正主要体现在 Excel/DB，避免隐藏文字层与肉眼可见原件发生不可追溯的“智能改写”。

如果自建文字层在 Acrobat/Edge/Chrome 等常用查看器中的搜索、复制、中文编码或坐标效果不达标，则回退 OCRmyPDF/Tesseract 作为独立 searchable PDF 后端。

Searchable PDF 必须在文件名和处理报告中表明其文字层由 OCR 辅助生成，原扫描图保持不变。

21. 项目数据库与断点恢复

每个任务建立本地 project database（SQLite）并记录 page state：

PENDING / PROCESSING / DONE / PAGE_ERROR / REVIEW_REQUIRED

页面处理成功即持久化。程序崩溃、重启或用户暂停后从未完成页继续。

活动 project DB 默认放在本地工作区，不建议把正在写入的 SQLite 工程直接放在不稳定网络共享盘；最终输出可导出到用户指定的本地或内部网络目录。

同一 Run 的模型、模板、解析器和规则版本必须固定。软件/模型在处理中途升级时，不得让同一 Run 前后使用不同版本。恢复旧 Run 时使用原版本依赖，或明确新建一个 Run 重新处理。

22. Run Manifest 与可追溯性

每次处理生成不可变 Run Manifest：

```
run_id
source_sha256
app_version
project_schema_version
ocr_engine
ocr_model_id
ocr_model_sha256
execution_provider
preprocess_profile_version
parser_version
template_id
template_version
validation_rules_version
exporter_version
started_at
completed_at
```

旧项目打开时不自动使用新算法重算。用户主动选择“使用最新算法重新识别”时创建新的 Run，并允许比较 Run 1 / Run 2。

22.1 Export Manifest

Run Manifest 固定识别运行环境；每次“导出”则额外生成 Export Manifest，避免人工复核后重新导出时修改原始 Run Manifest。Export Manifest 至少记录：export_id、run_id、exported_at、unresolved_count，以及结构化 Excel / searchable PDF / review report 的文件名、大小和 SHA-256。

23. 任务队列与资源调度

GUI 支持多个 PDF 排队，但 CPU 基线默认一次只主处理一个 PDF；单 PDF 内部有限并发。

worker 数必须由硬件探测和 benchmark 配置，不在代码里固定。提供标准/低资源运行策略；低资源模式限制 CPU 并发和缓存，保证 Word/Excel/浏览器仍可正常使用。

取消任务时保留已完成页面和项目数据库，可稍后继续或删除缓存。

24. Windows 桌面 UI

24.1 首页

- 拖放区；
- 当前任务与页进度；
- 已识别交易数；
- 待复核数量；
- 暂停/继续/取消；
- 最近项目。

24.2 文件体检页

显示：页数、扫描/原生比例、Native Text Quality Gate 结果、识别银行/模板、Generic 风险提示、输出项、扫描质量提示。若进入 Generic 且关键列不确定，文件体检完成后进入“列映射确认”页，再开始大批量处理。

24.3 异常复核页

左侧原 PDF/局部框选并支持同时高亮多个 source span；右侧显示上一笔/当前笔/下一笔、字段、raw blocks、secondary OCR、校验公式、建议值及确认操作；同时提供移动字段、合并交易、拆分交易、新增漏行、标记重复等结构修正。

24.4 设置页

只保留普通用户需要的设置：输出目录、工作目录、资源模式、处理完成提示、临时文件清理等。OCR 深层参数进入管理员/开发配置，不暴露给普通用户。

25. 临时文件与数据清理

默认采用流式处理，不保留全部中间页面图。复核页面由原 PDF 按需重新渲染；异常 crop 如保存，应支持项目完成后自动清理。

提供“清理项目缓存”功能，删除可重建的临时数据而保留源 PDF、最终输出和必要 manifest。删除动作需要明确确认。

26. 日志与诊断

默认日志仅记录技术事件：页号、阶段、耗时、模板 ID、错误类型、内存/性能信息，不记录 OCR 全文和敏感字段。

崩溃不自动上传。用户可手工“导出诊断包”，默认排除原 PDF、OCR 文字、数据库业务字段；如确需案例材料，由用户明确选择文件。

27. 打包与部署

V1 分发形态为 Windows 安装程序 + 桌面快捷方式，最终用户无需安装 Python。

当前优先部署路线：PySide6 / Qt Widgets + pyside6-deploy (Nuitka) 生成 standalone deployment；PyInstaller 作为兼容性备选，而不是默认路线。

程序、runtime、models、templates 分层部署，优先目录式安装而不是把所有模型和 Qt 强行塞入一个巨型 one-file EXE。

生产分发前必须完成：

- Windows 代码签名；
- 模型包签名或完整性校验；
- SBOM/第三方依赖清单；
- 开源许可证合规检查，包括 RapidOCR 工程代码、OCR 模型权利/许可、Qt/PySide6 及其他打包依赖；
- 杀毒/SmartScreen/企业终端环境兼容测试。

28. 完全离线验收

正式 V1 必须在断网或防火墙阻断环境下完成安装后运行测试：

- 不下载模型；
- 不请求 API；
- 不上传日志；
- 不自动更新；
- 不依赖在线字体/资源；
- 处理和导出功能完整可用。

网络零依赖属于发布验收项，而不仅是产品声明。

29. 模型、模板和方案升级

模型、模板、解析器、校验规则和 Application 分别版本化。

离线升级使用签名/哈希校验的 Model Pack / Template Pack。新模型不能因为“排行榜更高”直接替换生产模型，必须先运行完整 Regression Benchmark。

至少保留 Current / Previous 两个可用模型版本，并支持回滚。未完成 Run 引用的模型不得被自动删除。

未来可扩展多引擎策略，例如整页 OCR 使用模型 A，低置信数字 crop 使用模型 B；也可在 Generic 模式中加入本地 VLM，只用于识别表头/列结构和生成临时模板，不让 VLM 直接成为最终金额事实源。

30. 开发者模板工具

虽然 V1 不需要普通用户使用模板编辑器，但应提供开发/管理员级工具：

- 在样本页上叠加列边界、表格线、OCR bbox；
- 显示模板 fingerprint 分数；
- 导入/导出模板；
- 单页试跑 parser；
- 与 ground truth 比较；
- 生成模板回归报告。
- 将经项目 Temporary Template 验证过的候选模板提升为正式版本，并在发布前强制运行对应 ground truth / regression。

这样未来新增银行版式不必修改核心代码。

31. PoC → V1 开发阶段

PoC-0 : Golden Sample

将当前四页样本人工录入完整标准答案，建立首批 ground_truth。核心金额/余额/账号建议双人核对。这四页可作为早期 PoC 的 Calibration / Regression seed；如果后续开发曾针对它们调参，就不得再把它们计入 Locked Release Holdout。

退出条件： 每笔交易都有人工确认字段和原页定位。

PoC-1 : OCR Baseline

比较不同 DPI、灰度、deskew、对比度、阈值与 OCR 参数；锁定候选预处理 profile 和 RapidOCR baseline。

退出条件： 形成可重复的 OCR benchmark 报告和固定版本 manifest。

PoC-2 : Wired / Semi-Wired Parser

针对断续表格恢复横竖线、cell、跨行文本，并建立首个 Known Template。

退出条件： 交易行和列关联达到首轮验收目标。

PoC-3 : Positional Parser

针对无线表格完成表头列坐标、日期 row anchor、多行合并、印章干扰测试。

退出条件： 交易行关联可稳定复现。

PoC-4 : Validation + Secondary OCR

实现 Decimal、余额链、日期/账号规则、异常评分、局部二次 OCR。

退出条件： 对人工注入和真实 OCR 错误能够稳定报警，并显著降低人工复核量。

PoC-5 : Searchable PDF + Export

验证 PyMuPDF invisible text layer 的中文搜索/复制/定位，失败则 benchmark OCRmyPDF fallback；完成 Excel 和异常报告。

退出条件： 常用 PDF 查看器和 Excel 验收通过。

V1 Integration

接入 PySide6 GUI、任务队列、断点恢复、复核界面、安装包、离线部署。

V1 Release Hardening

扩大 Golden Set、运行回归、性能、安全、打包、网络零依赖、代码签名和升级回滚测试。

32. Benchmark 数据集

32.1 数据集分策略

V1 Benchmark 不使用“一套 Golden Set 既调参又验收”的方式。内部受控语料至少分为三层：

- Calibration Set：允许用于选择 DPI、预处理 profile、模板阈值、OCR/risk 阈值和候选规则；
- Regression Set：开发过程中反复运行，用于发现模型/模板/parser/validation 改动造成的回退；
- Locked Release Holdout：版本发布前才运行，禁止用于继续调参，是正式发布指标和 Silent Critical Error gate 的主要依据。

数据切分必须按文档/账户/银行版式家族进行，而不是把同一份流水的不同页面随机分到不同集合。来自同一 statement、同一账户连续页或高度同源扫描件必须留在同一集合，避免版式和上下文泄漏造成虚高指标。

32.2 覆盖范围与 Ground Truth

V1 发布前应逐步建立合计 500–1000 页的内部受控 Benchmark corpus（由 Calibration / Regression / Locked Release Holdout 组成），覆盖：

- 多家银行；
- 有线/断线/无线表格；
- 原生/扫描/混合 PDF；
- 200/300 DPI 与不同清晰度；
- 旋转/倾斜；
- 印章遮挡；
- 黑边/浅色/压缩噪声；
- 中文个人名/长公司名；
- 超长账号；
- 正序/倒序；
- 同日多笔/相同金额重复交易；
- 多币种；
- 多账号；
- 页面合计；
- 版式中途切换；
- 空白/重复/损坏页；
- 中文路径、长文件名和不同输出目录。

Ground Truth 必须来自人工核对原 PDF，而不是另一个 OCR 软件输出。

Ground Truth 还必须标注 row association 与 field-level source spans，确保不仅能评估“字认没认对”，还可以评估“这一字段是否属于正确交易、是否能回到正确原始位置”。Locked Release Holdout 的标注在冻结后不得因模型输出而反向修改；发现标注错误时应通过独立审校流程更正并记录版本。

33. 验收指标

33.1 Known Template 目标

- Locked Release Holdout: Transaction Recall $\geq 99.5\%$;
- Locked Release Holdout: 日期/金额/余额 Exact Match $\geq 99.5\%$;
- Locked Release Holdout: Row Association Accuracy $\geq 99\%$;
- Locked Release Holdout: 人工复核率 $\leq 10\%$;
- Silent Critical Error: Locked Release Holdout 上 0 个已知未报警关键错误；Regression Set 同样不得出现新增 Silent Critical Error。

“Silent Critical Error”定义为：最终结构化数据中的日期、金额、余额、交易行存在性或关键账号发生实质错误，但系统没有标记为 Review/Page Review。

发布指标只允许从冻结的 Locked Release Holdout 和明确版本的 Regression Set 生成。Calibration Set 可以作为工程诊断数据，但不得作为对外/内部发布质量结论的唯一依据。

33.2 Generic Mode 目标

Generic 模式以“避免错误自信”为优先，准确率目标低于 Known Template。首发目标：

- Transaction Recall $\geq 97\%$;
- Critical Field Exact Match $\geq 98\%$;
- 无法可靠映射关键列时 fail-closed;
- 新版式首批页必须高比例复核。

33.3 Searchable PDF

- Acrobat Reader、Edge/Chrome PDF Viewer 至少覆盖主流环境验收;
- 中文关键字可搜索;
- 搜索结果位置与可见文本基本对齐;
- 原始扫描图像保持不变;
- 生成失败不影响结构化 Excel 结果。

33.4 性能与资源

固定 10/50/200 页测试集，记录：总耗时、页/分钟、各阶段耗时、peak RAM、CPU 使用率、二次 OCR 占比、GUI 响应性。


性能优化不得以降低关键字段验收指标为代价。

34. 测试体系

- **Unit Tests:** Decimal、日期、标准化、规则、坐标变换;
- **Parser Tests:** 使用固定 TextBlock/bbox，不依赖 OCR，验证交易重建;
- **End-to-End Tests:** PDF $\rightarrow$ Excel/Review/PDF;
- **Regression Tests:** 每次模型/模板/parser/validation 改动全量跑;
- **Data Leakage Audit:** 检查 Calibration / Regression / Locked Holdout 是否存在同 statement、同账户连续页或近重复文档跨集合;
- **Native Text Fallback Tests:** 构造乱码文字层、错位 bbox、缺字文字层，验证 Quality Gate 能回退 OCR;
- **Review Structure Tests:** 验证合并/拆分/移动/新增交易后 source_spans、审计记录和重新导出均保持一致;
- **Packaging Tests:** 全新 Windows 虚拟机/实体机安装与卸载;
- **Offline Tests:** 防火墙阻断后全流程;
- **Failure Tests:** 损坏页、低磁盘、强制退出、断点恢复、异常字符路径;
- **Upgrade Tests:** 新模型安装、旧 Run 打开、回滚、未完成任务恢复。

35. 项目目录建议

```
bankocr/
├── app/
│   ├── gui/
│   ├── task_manager/
│   └── settings/
├── core/
└── pdf/
```



36. 数据库与项目格式升级

SQLite schema 必须有 project_schema_version 和 migration 机制。软件升级不得假设旧数据库结构等同于当前结构。

项目文件格式升级必须可测试、可失败回滚；迁移前保留本地备份或事务保护。旧 Run 的来源链和 manifest 不因 schema migration 被重写。

37. 风险与缓解

风险	影响	V1 缓解
OCR 数字误识别	金额/余额错误	Decimal + 余额链 + 二次 OCR + Review
OCR 全字正确但串行/串列	对手/金额关联错误	坐标 parser + Row Association benchmark
Generic 误判列结构	大量静默错表	fail-closed + 降低信任 + 首批页复核
deskew 后 bbox 错位	复核框/文字层错位	CoordinateTransform 全链保存
200 页占用过大	卡死办公电脑	流式页面处理 + 有界 worker + 低资源模式
软件中途升级	同一项目结果不可复现	Run pinning + manifest + old engine retention
搜索 PDF 文字层偏移	搜索体验差	viewer benchmark + OCRmyPDF fallback

敏感数据写入日志/临时目录	隐私风险	最小日志 + 本地 workspace + 自动清理
新模型关键字段回退	生产质量下降	Golden Set regression + critical field gate
依赖/许可证问题	无法正式部署	SBOM + license review + signed release
Benchmark 数据泄漏/过拟合	发布指标虚高	Calibration / Regression / Locked Holdout 分层 + statement-level split
原生 PDF 文字层损坏	乱码/缺字被当成高可信文本	Native Text Quality Gate + OCR fallback
字段来自多 OCR block 但只保存单 bbox	追溯不完整/结构修正丢来源	field-level source_spans[] + raw_blocks[]
串行/合并/拆分错误无法人工修复	Excel 结构仍然错误	Review UI 交易级结构修正 + 审计链
Generic fail-closed 后无恢复路径	陌生银行大量停在 PAGE_REVIEW	首屏列映射确认 + project-scoped Temporary Template

38. 设计审查后纳入的关键修改 (v1.0 → v1.1)

v1.1 设计复审保留 v1.0 已锁定的 16 项要求，并新增/强化以下开发基线：

1. 整份 PDF 类型检测改为页级检测，支持原生/扫描混合文件；
2. 新增 **CoordinateTransform**，保证 skew/缩放后仍可准确回到原 PDF 坐标；
3. 中间图改为流式处理，不默认保存 200 页完整 PNG，降低内存、磁盘和隐私风险；
4. **Generic Parser 改为 fail-closed**，关键列不确定时不强行生成可信 Excel；
5. 删除固定 80% 模板阈值和固定 **OCR confidence 阈值**，改由 Golden Set 校准并版本化；
6. 新增 **statement_stream_id**，禁止跨账户/币种/区段错误串接余额链；
7. 新增重复页、空白页、损坏页、页面方向突变检测；
8. 新增 **Silent Critical Error** 指标，作为发布 gate；
9. **Searchable PDF** 默认不把“智能修正”静默写入隐藏层，结构化修正保留在 Excel/DB provenance；
10. 打包主路线改为 **pyside6-deploy/Nuitka**，PyInstaller 作为 fallback；
11. **GPU 自动加速从 V1 承诺中移除**，ONNX CPU 为唯一强制基线，OpenVINO 仅经 benchmark 后可选；
12. 新增 **project schema migration、Run pinning 和旧 Run 不自动重算**；

13. 新增 Windows 代码签名、Model Pack 完整性、SBOM/许可证审查和真正断网验收；
14. 人工修改后可直接重新导出，不需要重新 OCR；
15. 新增“原件不可辨认”状态，系统不得为不可辨认内容强行生成最终值；
16. 活动 SQLite 工作区默认本地化，降低网络共享盘导致的中断和锁问题。
17. Benchmark 拆分为 Calibration / Regression / Locked Release Holdout，并按 statement/账户/版式家族切分，禁止同源页面泄漏；
18. ProvenanceValue 从单一 source_bbox 升级为 raw_blocks[] + source_spans[]，支持一个最终字段追溯多个原始 OCR block；
19. 人工复核从“改单字段”升级为字段 + 交易结构双层修正，支持移动字段、合并/拆分交易、新增漏行和标记重复；
20. Generic fail-closed 增加首屏列映射确认，生成 project/Run scoped Temporary Template，避免陌生银行只能停在 PAGE_REVIEW；
21. 确定性校验规则引入 PASS / FAIL / INDETERMINATE / NOT_APPLICABLE 四态，避免把“无法判断”误报为确定错误；
22. 原生 PDF 增加 Native Text Quality Gate，异常文字层自动回退 Rasterize + OCR，native text 不再使用伪造的 confidence=1.0；
23. 模板坐标由单纯 page-relative 升级为 table box / header anchor 归一化坐标，page-relative 仅作为 fallback；
24. 每次导出生成 Export Manifest，并记录结构化 Excel、可搜索 PDF、异常报告的 SHA-256；
25. 复核界面默认提供上一笔/当前笔/下一笔上下文，并可同时高亮一个字段的多个 source span。

39. 后续版本路线

V1.5

- 完整管理员模板编辑器（V1 仅提供 Generic 列映射确认与开发工具；V1.5 再产品化正式模板编辑/发布流程）；
- OpenVINO/其他 CPU 后端 benchmark 后可选启用；
- 更成熟的模板包离线分发；
- 可选便携式部署包。

V2

- 本地 VLM 仅用于 Unknown Template 的版面理解/临时模板生成；
- 多 OCR Engine 局部仲裁；
- 更强的陌生银行自适应。

V2.5

- 本地全文/字段检索；
- 按姓名、账号、金额区间快速筛选并跳回原 PDF。

V3

- 交易对手归集；
- 大额/快进快出规则；
- 资金路径与关系分析；
- 本地 LLM/图分析作为辅助研判层。

40. V1 设计锁定结论

V1 采用“轻量 OCR + 版面几何 + 银行模板 + 确定性校验 + 人工复核”的组合架构。

RapidOCR/PP-OCRV6-small 是 V1 的首个 OCR Engine，而不是产品永久绑定的唯一模型。系统从第一天就把 OCR Engine、Parser、Bank Template、Validation Rules、Application 和 Project Schema 分离并版本化，以支持未来模型升级、模板扩展、VLM 辅助和算法回滚。

V1 的质量核心不是单纯追求 OCR 平均准确率，而是：**尽量不漏交易、关键数字可校验、所有不确定性可暴露、人工复核足够快、最终值可追溯到原 PDF。**

其中，“机器建议值”和“人工/确定性确认后的最终值”在数据层必须永久分离；升级模型、修改模板或重新导出都不能抹掉历史来源链。

v1.1 进一步要求：字段值与交易结构都必须可追溯、可人工修正且不覆盖机器原始候选；正式质量结论必须来自冻结的 Locked Release Holdout，Generic 与 Native Text 两类“不确定来源”都必须存在明确的 fail-closed / fallback 恢复路径。

参考技术基线（截至 2026-08-07）

- RapidOCR 文档：PP-OCRV6 small 为 RapidOCR 3.9.x 的默认 det/rec 组合，支持 ONNX Runtime / OpenVINO 等执行后端。
https://rapidai.github.io/RapidOCRDocs/main/install_usage/rapidocr/usage/
- RapidOCR PyPI：当前可见 3.9.2（2026-07-21），生产 PoC 仍需固定并哈希具体 wheel/模型。
<https://pypi.org/project/rapidocr/>
- ONNX Runtime Windows：Windows ML/WinML 是 Microsoft 当前推荐的 Windows 开发路径；DirectML 独立 EP 处于 sustained engineering。
<https://onnxruntime.ai/docs/get-started/with-windows.html>
- ONNX Runtime OpenVINO EP：
<https://onnxruntime.ai/docs/execution-providers/OpenVINO-ExecutionProvider.html>
- Qt for Python deployment：pyside6-deploy 为 Qt for Python 官方部署工具，底层使用 Nuitka。
<https://doc.qt.io/qtforpython-6/deployment/deployment-pyside6-deploy.html>
- PyMuPDF TextWriter：PDF render mode 3 可写 invisible text。
<https://pymupdf.readthedocs.io/en/latest/textwriter.html>
- OCRmyPDF：为扫描 PDF 添加可搜索 OCR text layer。
<https://ocrmypdf.readthedocs.io/en/stable/>